The bad guys in AI

atacando sistemas de machine learning

¿Porqué…?


ABC
REPORTAJES
Buscar
ORBYT
Tienda
SuVivienda
Empleo
Coches
Motor
Tendencias
Náutica
Viajes
Yodona
Metrópoli
Gentes de Verano!
Hemeroteca
ABC
MOTOR
Publicidad
Compartir
Twittear
Tuenti
Herramientas
Enviar a un
Valorar
Imprimir
En tu móvil
Rectificar
EL PAÍS
OPINIÓN
EDITORIALES
TRIBUNAS
COLUMNAS
VIÑETAS
VÍDEOS
CÓMO COLABORAR
CARTAS A LA DIRECTORA
NUESTRAS FIRMAS
QUIENES SOMOS
TRIBUNA ›
'Fake news' y credulidad
Cada vez con más frecuencia pensamos con una trama de datos e ideas facilitados por las redes. Creemos cualquier cosa que se presente con cierta contundencia; somos la población más informada de la historia, pero también la más vulnerable
JORDI SOLER
29 ABR 2018 - 00:00 CEST
Marcel Duchamp leyó dos libros de filosofía en su vida, uno de ellos con verdadera devoción. Leyó *El único y su propiedad*, de Max Stirner, y se apasionó con un pequeño volumen, que releyó varias veces cuando trabajaba en la biblioteca de Sainte-Geneviève, en el que se contaba la vida y las ideas de Pirrón de Elis.
El escepticismo radical de Pirrón sirvió

Javier Ordóñez & Alicia Pérez

Data Scientists @Style_Sage

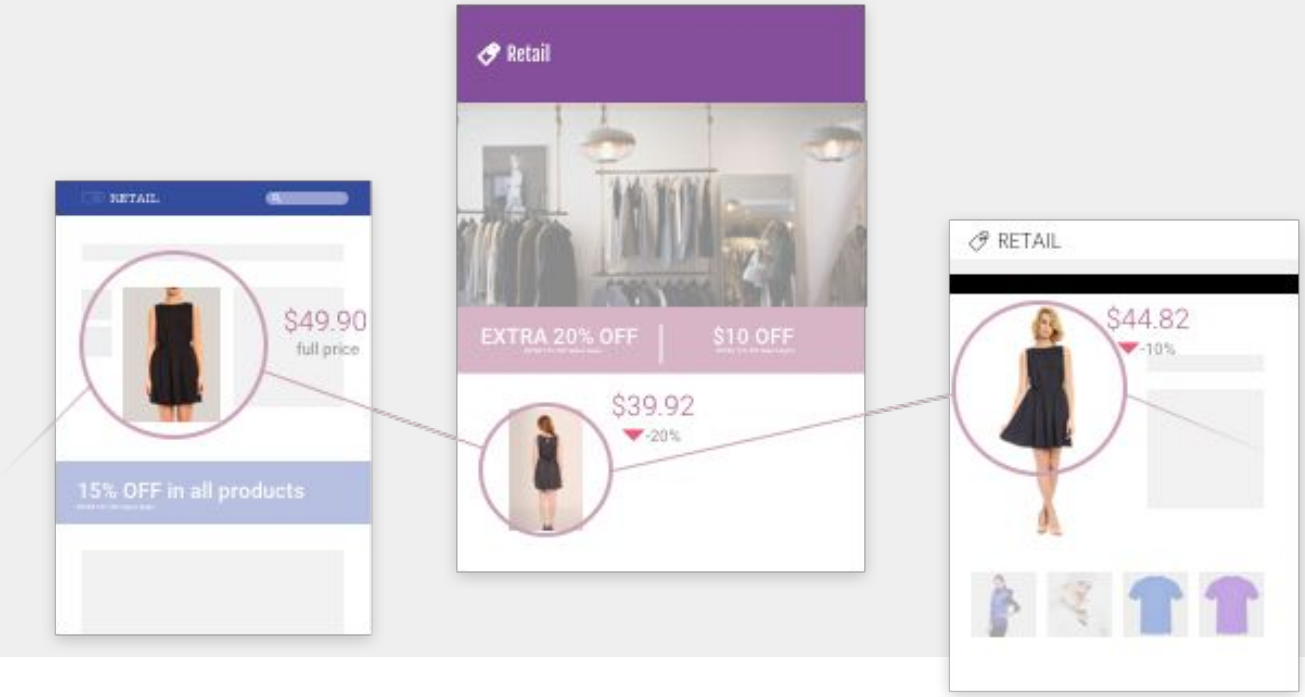

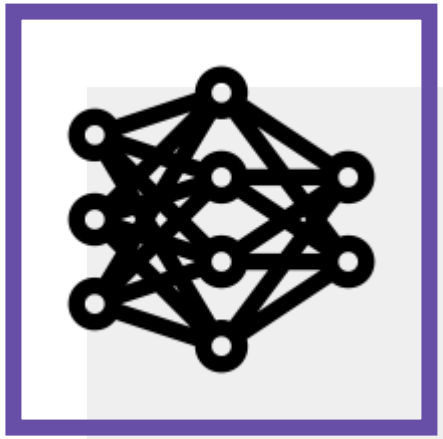

Redes neuronales

Qué es una red neural profunda y cómo aprende a clasificar datos

Red neural profunda

La imagen de entrada se transforma aplicando patrones organizados en una estructura jerárquica, extraídos mediante un método de optimización y una señal supervisora, para dar lugar a un vector de probabilidades.

CNN Demo

karpathy.github.io

Aprendizaje de características

- Inicialización aleatoria de los parámetros.
- Convergencia gracias a métodos de optimización.

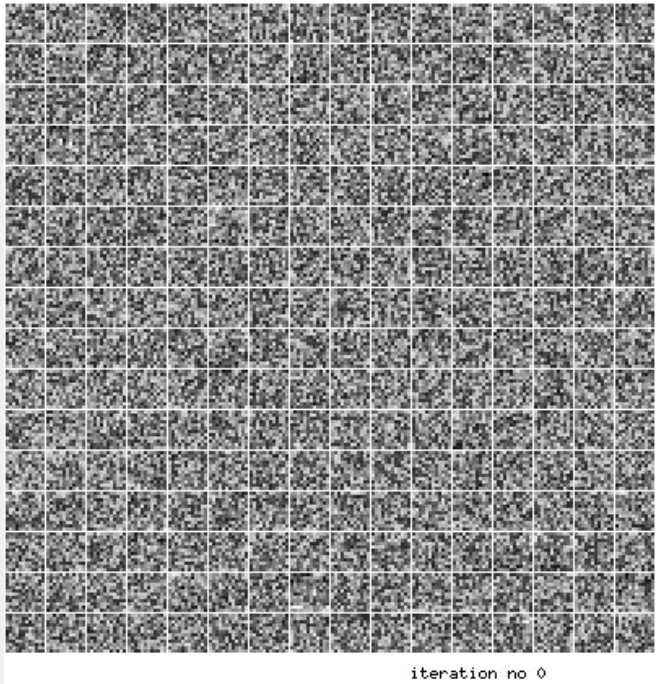

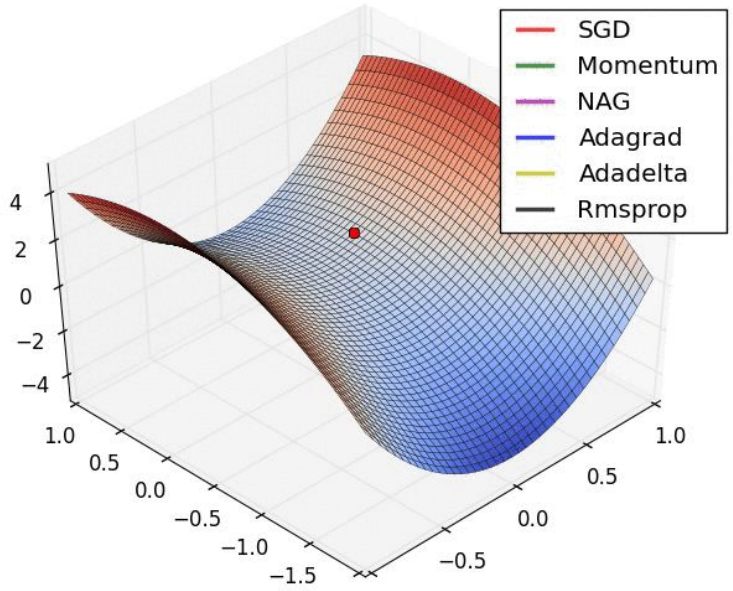

- Optimización basada en métodos de descenso del gradiente.
- Los parámetros se van moviendo hacia un punto que minimice el error del sistema.

blog.paperspace.com

Modelos discriminativos

- Dado un vector de características, predice una etiqueta.
- Probabilidad condicional.
- Modelan la dependencia entre una etiqueta (salida) y las características (datos de entrada)

Modelos generativos

- Crea ejemplos en vez de evaluarlos.
- Probabilidad conjunta.
- Modela cómo se distribuyen las características (datos de entrada) de cada tipo de etiqueta.

Evaluación de modelos discriminativos

p(Mopa) = 7%
p(Perro) = 93%

p(Mopa) = 87%
p(Perro) = 13%

Evaluación de modelos generativos

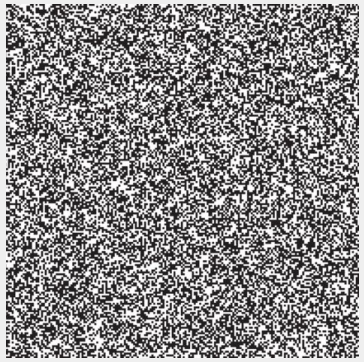

?

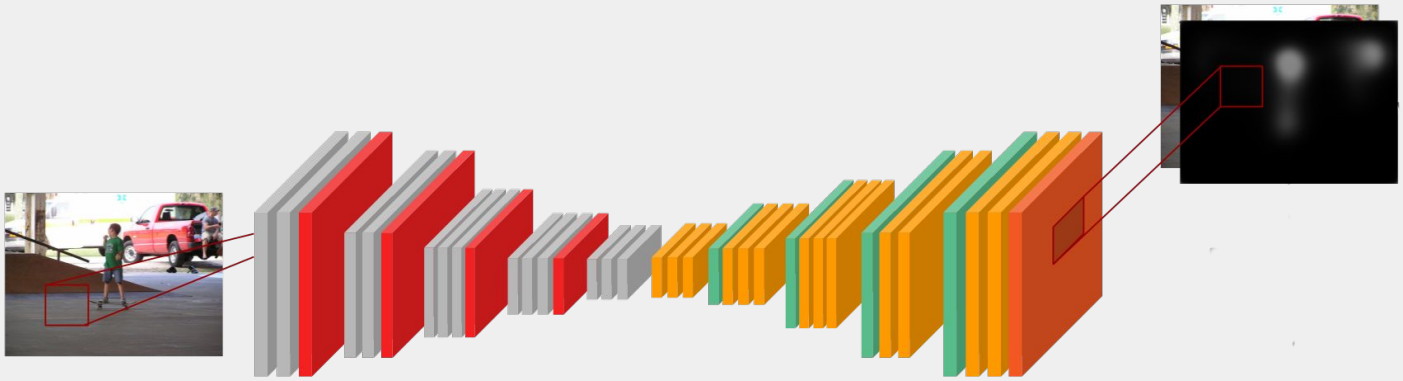

Arquitecturas adversarias

Redes generativas adversarias

- La salida del bloque generativo es una muestra o ejemplo.
- La salida del bloque discriminativo es la clasificación de la muestra. **La señal supervisora de la que se aprende.**

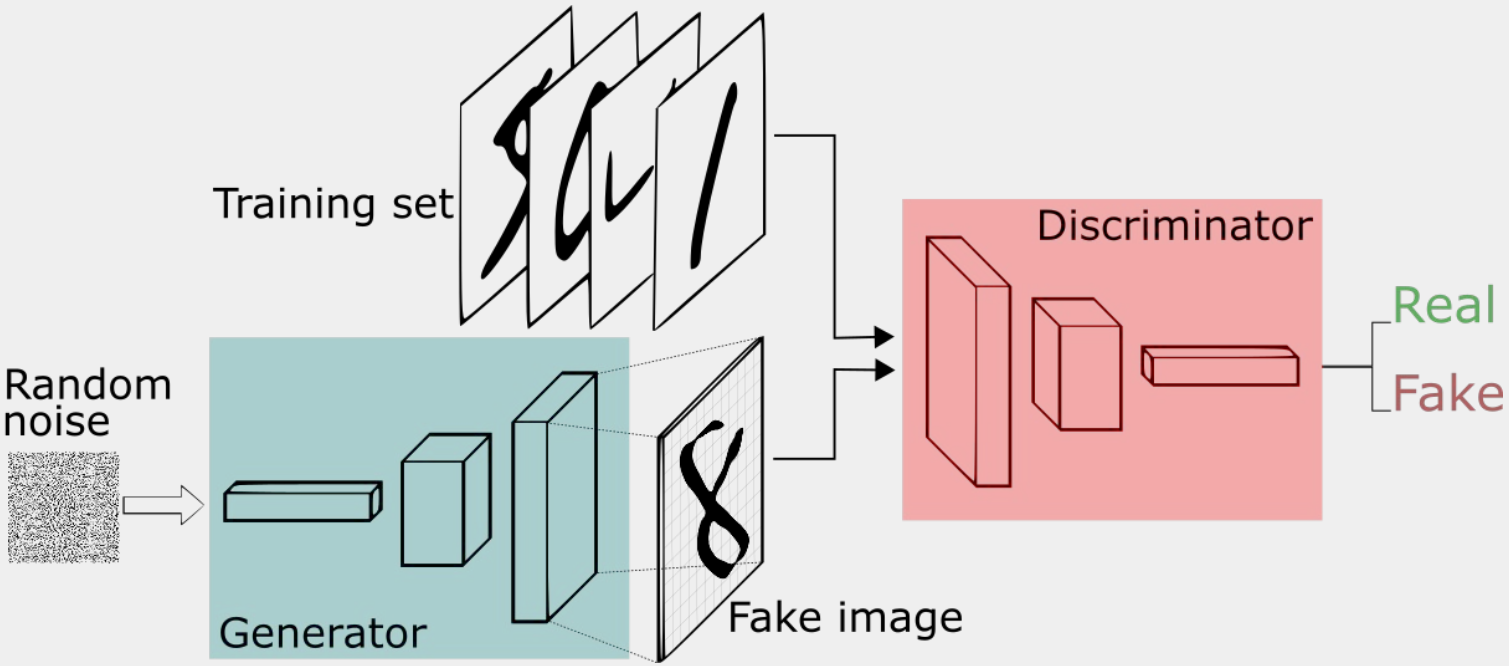

towardsdatascience.com

Generación de datos sintéticos

El modelo generativo comienza aleatoriamente y converge hacia representaciones que se asemejan a los datos usados para entrenar al modelo discriminativo.

No aprende a **clasificar**

Aprende a **engañar**

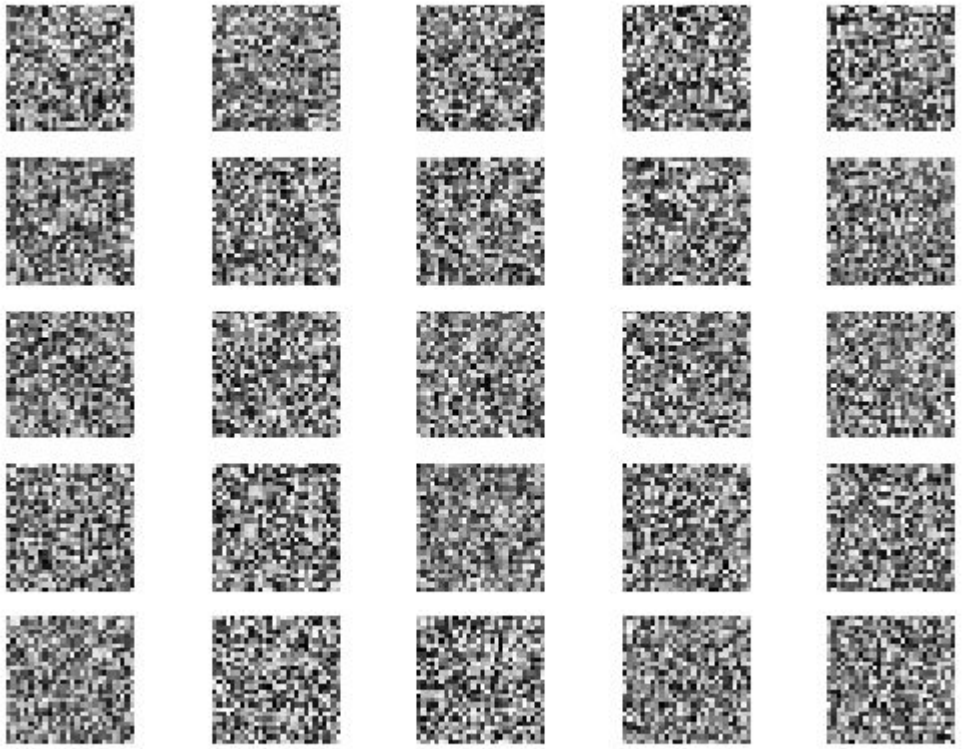

Ejemplo de generación de imágenes

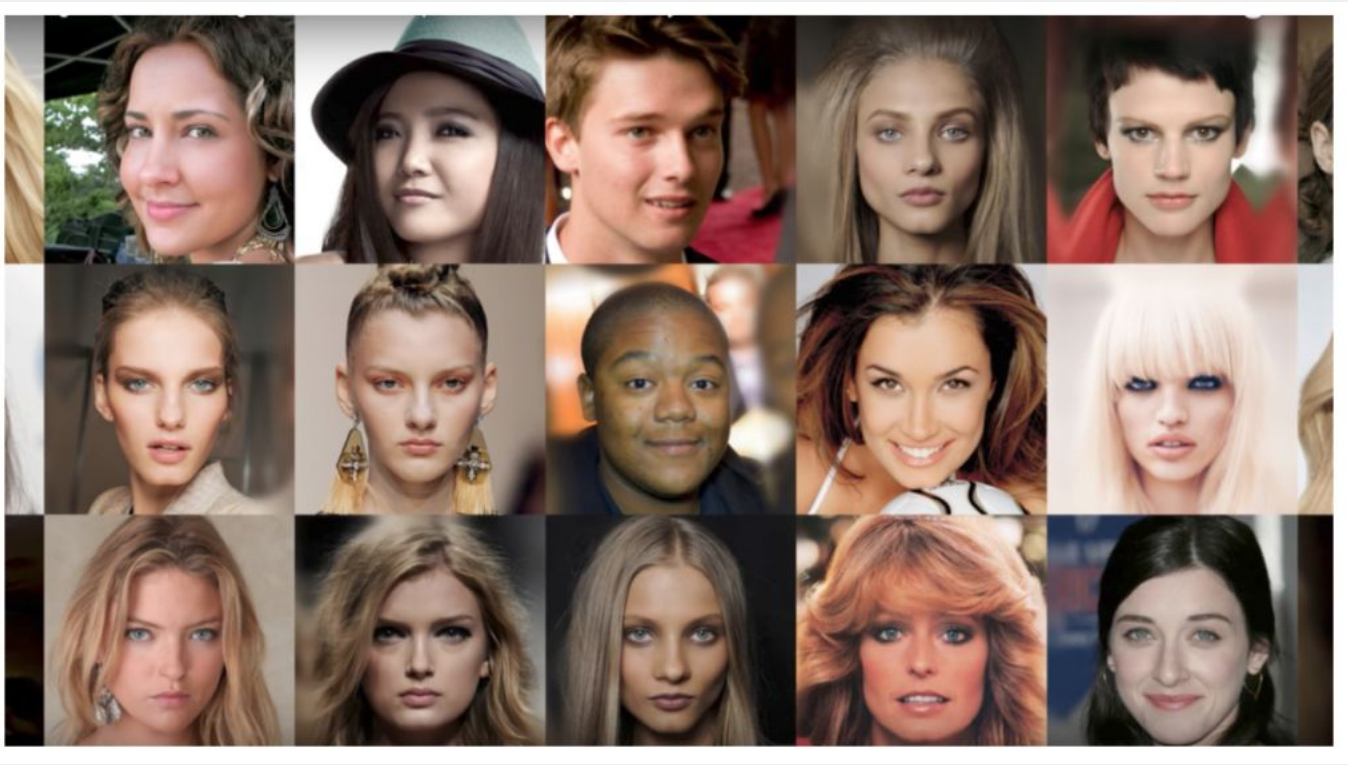

"Progressive growing of gans for improved quality, stability, and variation". *Karras et. al.*

Ejemplo de generación de imágenes

"Progressive growing of gans for improved quality, stability, and variation". *Karras et. al.*

Concepto de ataque

Ejemplo antagónico

Muestra perteneciente a la distribución de los datos alterada mínimamente para que sea clasificada incorrectamente.

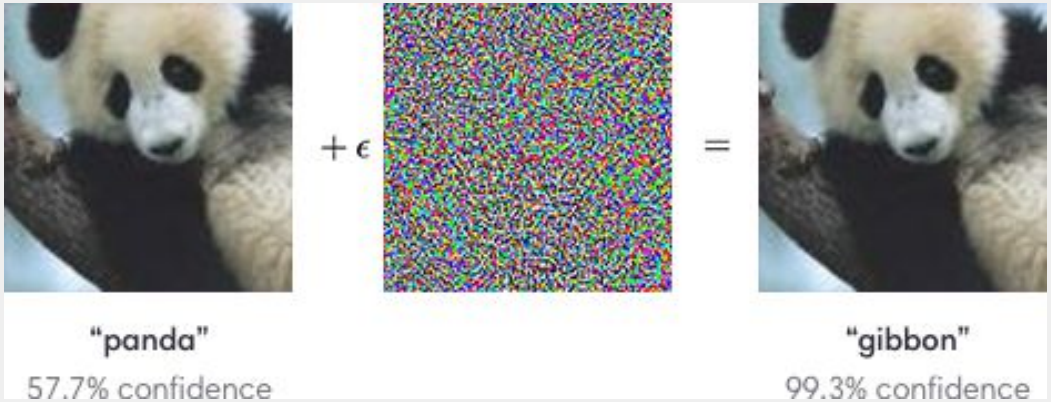

Ataque antagónico

Entrenamiento de modelo generativo adversario que es capaz de crear muestras sintéticas para engañar a un modelo discriminativo objetivo.

Tipos de ataque

No orientado

El más habitual

Sólo se busca que el clasificador ofrezca un resultado incorrecto

Orientado

Más difícil

Busca obtener una clase específica.

Caja blanca

Tenemos acceso al modelo:

- Arquitectura
- Parametrización
- Datos

Caja negra

Sólo disponemos de la salida del modelo a atacar

Ataque no orientado de caja negra

Crear datos sintéticos → **Etiquetar con el modelo "oráculo"** → Entrenar modelo "sustituto" → Crear ejemplos antagónicos

Ataque no orientado de caja negra

Crear datos sintéticos → Etiquetar con el modelo “oráculo” → **Entrenar modelo “sustituto”** → **Crear ejemplos antagónicos**

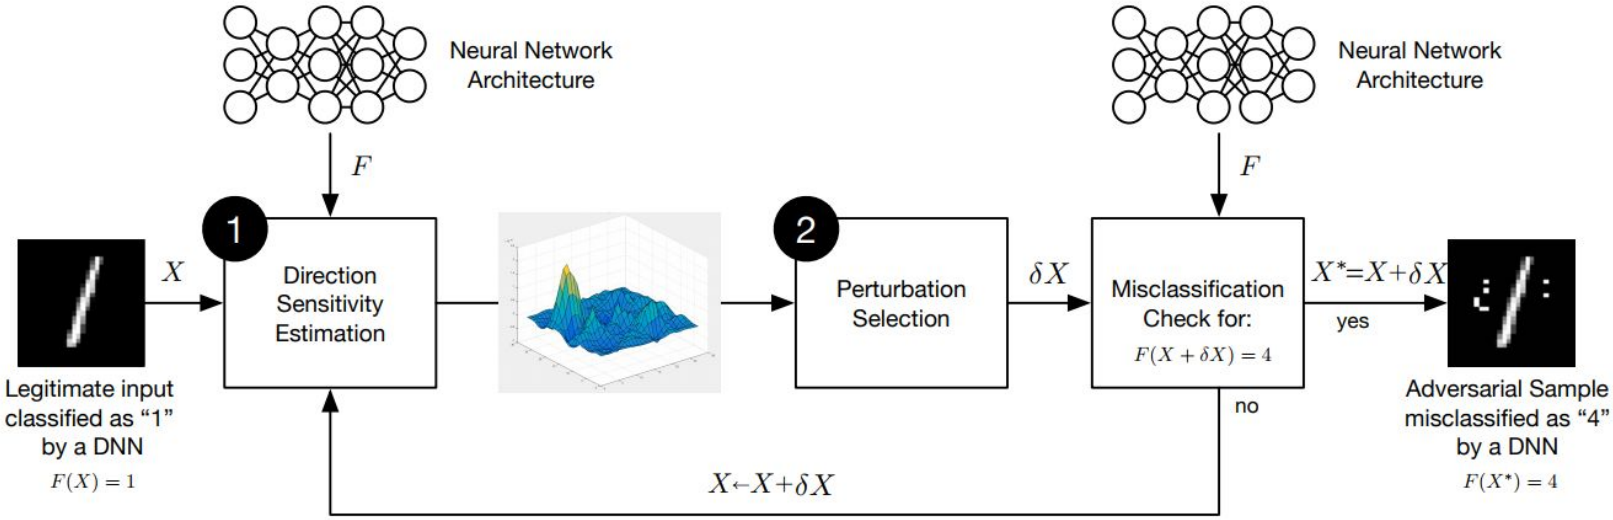

Demo time

Cómo atacar un sistema de clasificación de imágenes de comida

Antes de empezar…

Ataqu

1. E
   ir
2. E
   ir
3. A

clasificar

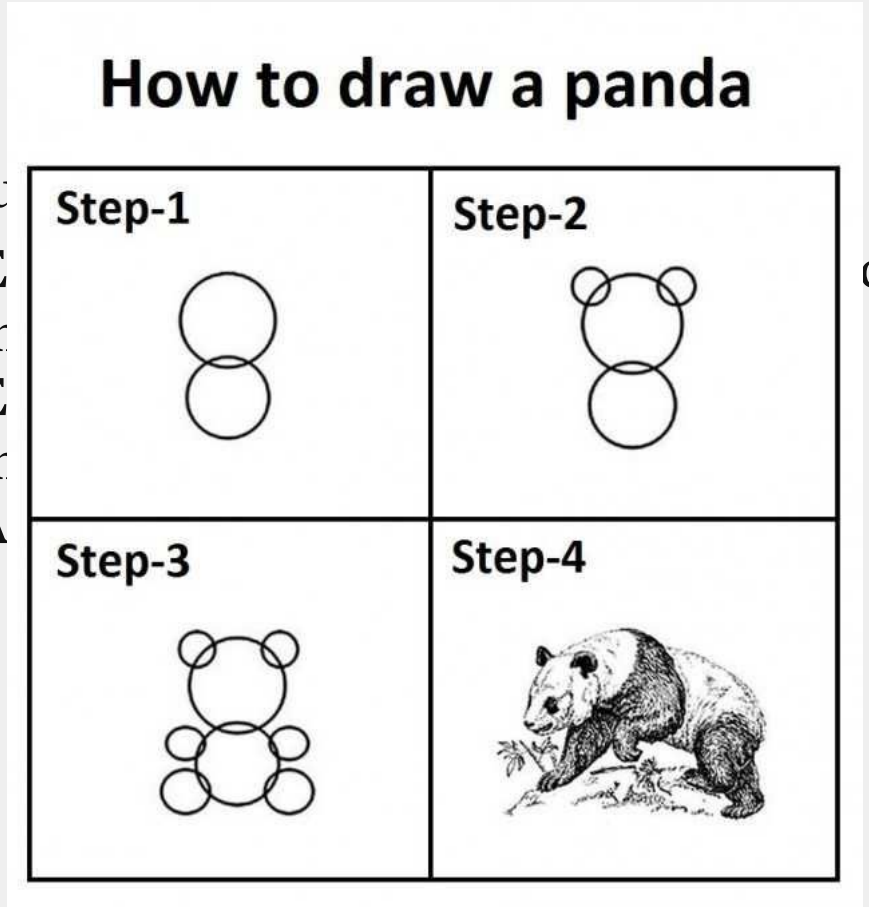

¡¡No es trivial!!

Dataset

Food-11- Etiquetas con 11 tipos de comida. Imágenes: 16643

Food-5K - Etiquetas binarias. Imágenes: 2500 comida, 2500 no comida

Dataset

Food-12

- Incluye 12 etiquetas
- Tamaño: 19125 imágenes
- Dividido en:
  - Entrenamiento
  - Validación
  - Test
- Tamaño de entrenamiento aumentado

Categoria	Imágenes
Bread	1724
Dairy product	721
Dessert	2500
Egg	1648
Fried food	1461
Meat	2206
Noodles/Pasta	734
Rice	472
Seafood	1505
Soup	2500
Vegetable/Fruit	1154
Non food	2500

Modelo discriminativo

Red neuronal `InceptionV3`

Keras

- 23.851.784 parámetros
- 159 capas
- Pre-entrenada en Imagenet
- Reentrenamiento de capas profundas

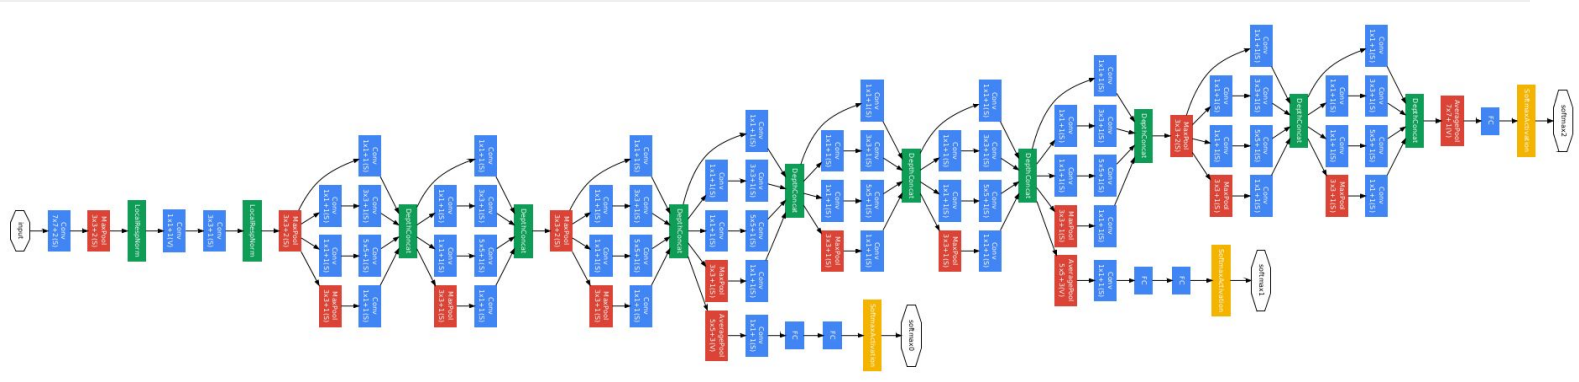

```
from keras.applications.inception_v3 import preprocess_input
from keras.preprocessing.image import ImageDataGenerator


IM_WIDTH, IM_HEIGHT = 299, 299  # fixed size for InceptionV3
BATCH_SIZE = 32

train_datagen = ImageDataGenerator(
    preprocessing_function=preprocess_input,
    rotation_range=30,
    width_shift_range=0.2,
    height_shift_range=0.2,
    shear_range=0.2,
    zoom_range=0.2,
    horizontal_flip=True)

training_path = os.path.join(source_path, 'training/')
train_generator = train_datagen.flow_from_directory(
    training_path,
    target_size=(IM_WIDTH, IM_HEIGHT),
    batch_size=BATCH_SIZE)
nb_classes = train_generator.num_classes
```

discriminative/model_manager.py

```
from keras.applications.inception_v3 import preprocess_input
from keras.preprocessing.image import ImageDataGenerator


IM_WIDTH, IM_HEIGHT = 299, 299  # fixed size for InceptionV3
BATCH_SIZE = 32

train_datagen = ImageDataGenerator(
    preprocessing_function=preprocess_input,
    rotation_range=30,
    width_shift_range=0.2,
    height_shift_range=0.2,
    shear_range=0.2,
    zoom_range=0.2,
    horizontal_flip=True)

training_path = os.path.join(source_path, 'training/')
train_generator = train_datagen.flow_from_directory(
    training_path,
    target_size=(IM_WIDTH, IM_HEIGHT),
    batch_size=BATCH_SIZE)
nb_classes = train_generator.num_classes
```

"Aumento" del dataset de entrenamiento

Carga de los datos con Keras

discriminative/model_manager.py

```
from keras.applications.inception_v3 import InceptionV3
from keras.callbacks import EarlyStopping
from keras.models import Model, load_model
from keras.layers import Dense, GlobalAveragePooling2D
from keras.optimizers import SGD

base_model = InceptionV3(weights='imagenet', include_top=False)
x = base_model.output
x = GlobalAveragePooling2D()(x)
x = Dense(FC_SIZE, activation='relu')(x)  # new FC layer, random init
predictions = Dense(nb_classes, activation='softmax')(x)
model = Model(input=base_model.input, output=predictions)

for layer in model.layers[:NB_IV3_LAYERS_TO_FREEZE]:
    layer.trainable = False
    model.compile(optimizer=SGD(lr=0.0001, momentum=0.9),
                  loss='categorical_crossentropy',
                  metrics=['accuracy'])

early_ft = EarlyStopping(monitor="val_loss", patience=3)
history_ft = model.fit_generator(train_generator,
 samples_per_epoch=nb_train_samples,
 nb_epoch=NB_EPOCHS_FINETUNE,
 validation_data=validation_generator,
 nb_val_samples=nb_val_samples,
 class_weight='auto',
 callbacks=[early_ft])
model.save(OUTPUT_MODEL_FILE)
```

discriminative/model_manager.py

```
from keras.applications.inception_v3 import InceptionV3
from keras.callbacks import EarlyStopping
from keras.models import Model, load_model
from keras.layers import Dense, GlobalAveragePooling2D
from keras.optimizers import SGD
```

Carga de Inception

```
base_model = InceptionV3(weights='imagenet', include_top=False)
x = base_model.output
x = GlobalAveragePooling2D()(x)
x = Dense(FC_SIZE, activation='relu')(x)  # new FC layer, random init
predictions = Dense(nb_classes, activation='softmax')(x)
model = Model(input=base_model.input, output=predictions)

for layer in model.layers[:NB_IV3_LAYERS_TO_FREEZE]:
    layer.trainable = False
    model.compile(optimizer=SGD(lr=0.0001, momentum=0.9),
                  loss='categorical_crossentropy',
                  metrics=['accuracy'])
```

Transfer learning

```
early_ft = EarlyStopping(monitor="val_loss", patience=3)
history_ft = model.fit_generator(train_generator,
 samples_per_epoch=nb_train_samples,
 nb_epoch=NB_EPOCHS_FINETUNE,
 validation_data=validation_generator,
 nb_val_samples=nb_val_samples,
 class_weight='auto',
 callbacks=[early_ft])
model.save(OUTPUT_MODEL_FILE)
```

Entrenamiento de las últimas capas

discriminative/model_manager.py

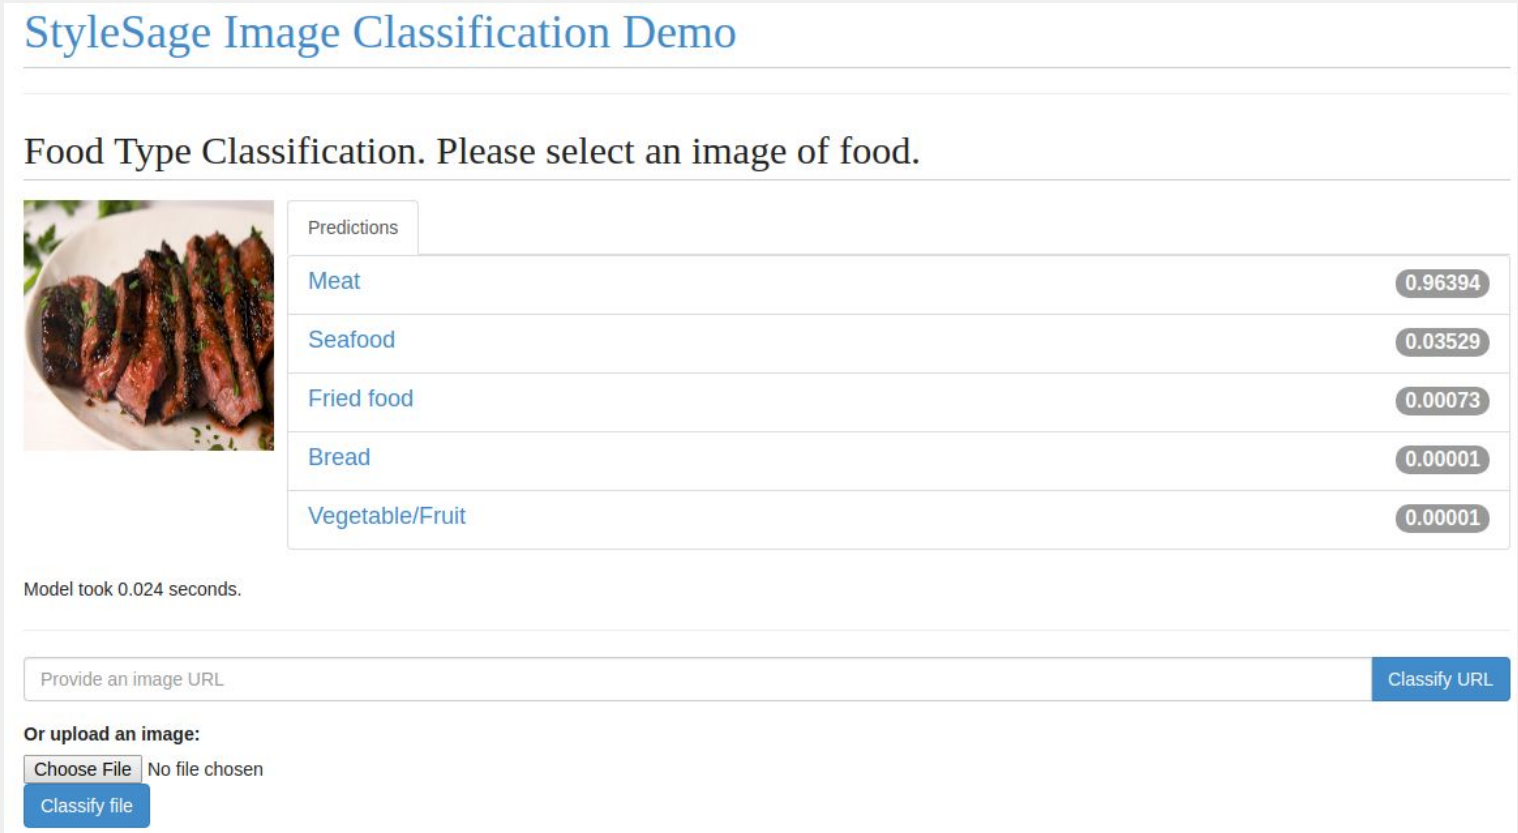

Rendimiento - **91% exactitud**

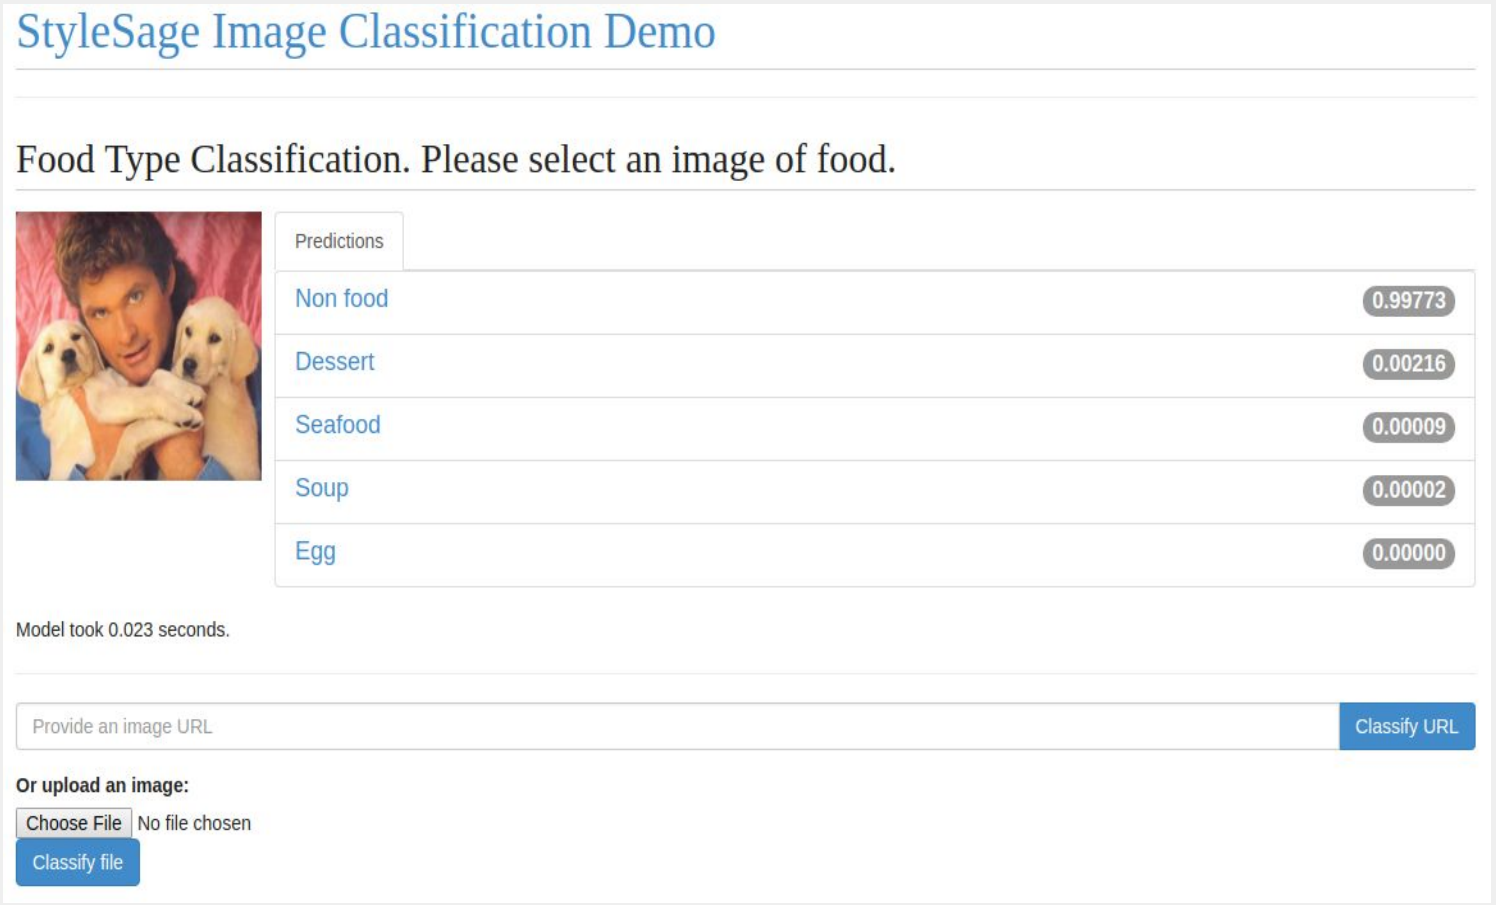

Rendimiento - **91% exactitud**


Hey, Don't even worry about it.

Modelo generativo

"An adversarial example library for constructing attacks, building defenses, and benchmarking both"

by Goodfellow and Papernot

- La librería más actual y completa (v2.1.0):
  - Modelos (en Tensorflow, Keras, Pytorch...)
  - Ataques (Fast gradient sign method, Carlini-Wagner attack...)
  - Defensas (Adversarial training)
  - ....

"cleverhans v1.0.0: an adversarial machine learning library". *Goodfellow and Papernot.*

Ataque no orientado de caja negra

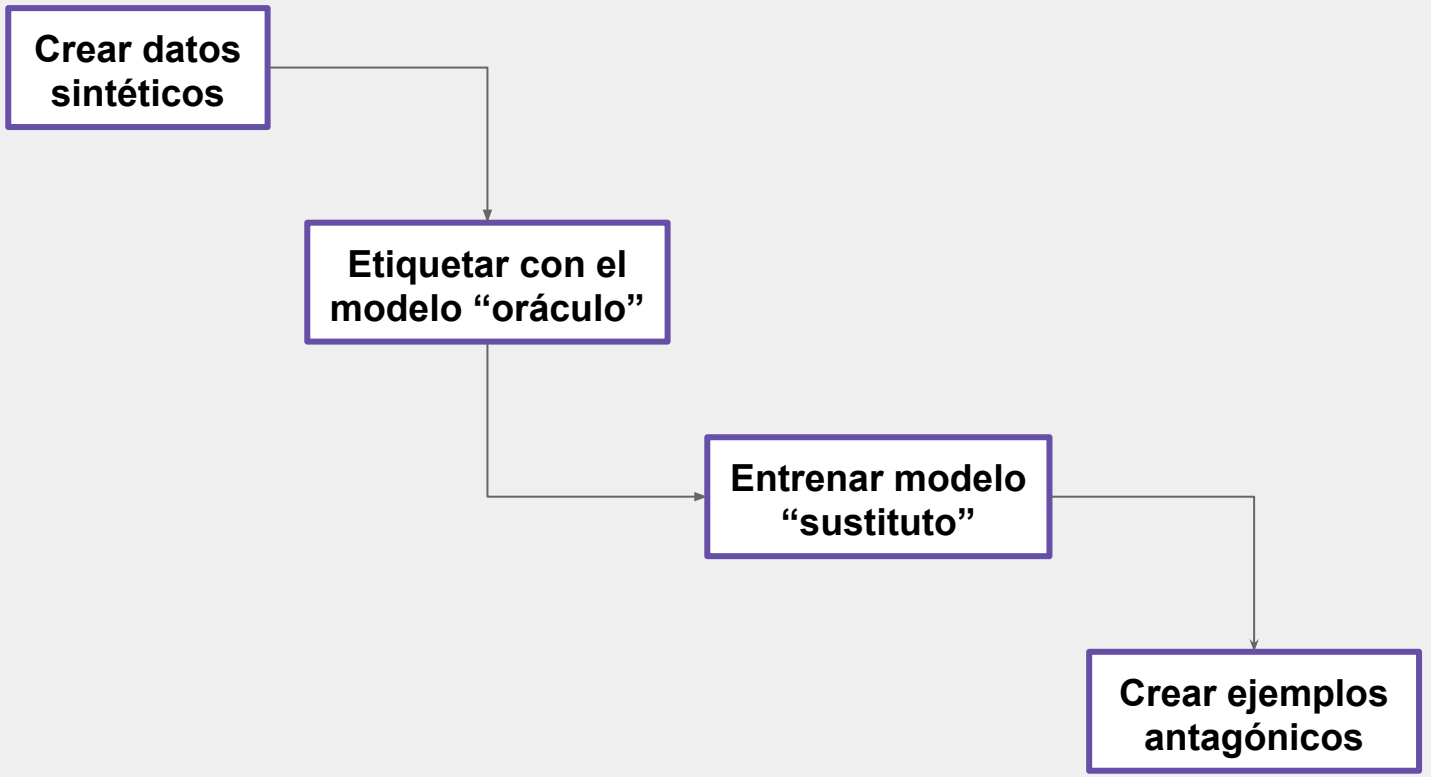

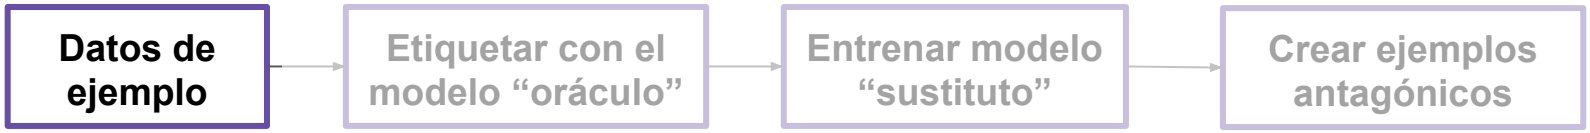


```
train_generator = train_datagen.flow_from_directory(
    '/data/pycon18/data/randomfood/training' ,
    target_size=(IM_WIDTH, IM_HEIGHT),
    batch_size=BATCH_SIZE,
)
validation_generator = test_datagen.flow_from_directory(
    '/data/pycon18/data/randomfood/evaluation' ,
    target_size=(IM_WIDTH, IM_HEIGHT),
    batch_size=BATCH_SIZE,
)

x_train, y_train = train_generator.next()
x_test, y_test = validation_generator.next()

# Initialize substitute training set reserved for adversary
X_sub = x_test
Y_sub = np.argmax(y_test, axis=1)
```

attack/pycon_blackbox_keras.py

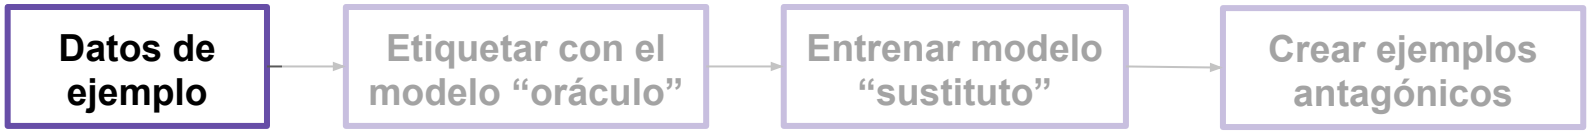


```
train_generator = train_datagen.flow_from_directory(
    '/data/pycon18/data/randomfood/training',
    target_size=(IM_WIDTH, IM_HEIGHT),
    batch_size=BATCH_SIZE,
)
validation_generator = test_datagen.flow_from_directory(
    '/data/pycon18/data/randomfood/evaluation',
    target_size=(IM_WIDTH, IM_HEIGHT),
    batch_size=BATCH_SIZE,
)
```

```
x_train, y_train = train_generator.next()
x_test, y_test = validation_generator.next()

# Initialize substitute training set reserved for adversary
X_sub = x_test
Y_sub = np.argmax(y_test, axis=1)
```

Carga de imágenes

Necesitamos separar train y eval para el modelo sustituto

attack/pycon_blackbox_keras.py

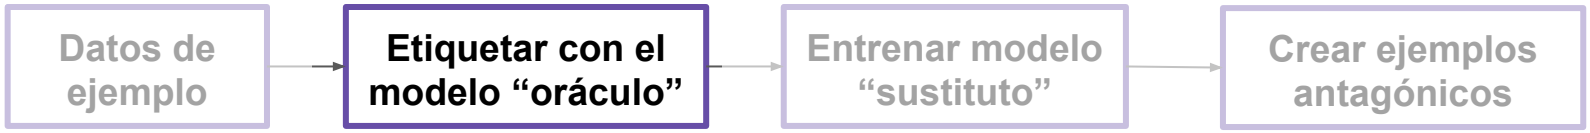


```
model = load_model('/data/pycon18/inceptionv3-ft120_910acc.model')
kmodel = KerasModelWrapper(model)
bbox_preds = kmodel.get_probs(x)

# You could replace this by a remote labeling API for instance
```

attack/pycon_blackbox_keras.py

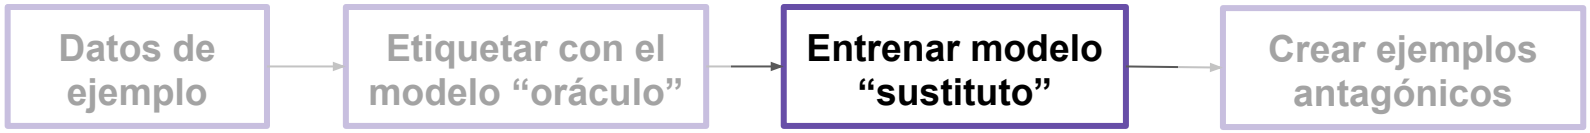


```
class ModelSubstitute(Model):
    def __init__(self, scope, nb_classes, nb_filters=200, **kwargs):
        del kwargs
        Model.__init__(self, scope, nb_classes, locals())
        self.nb_filters = nb_filters

    def fprop(self, x, **kwargs):
        del kwargs
        my_dense = functools.partial(
            tf.layers.dense, kernel_initializer=HeReLuNormalInitializer)
        with tf.variable_scope(self.scope, reuse=tf.AUTO_REUSE):
            y = tf.layers.flatten(x)
            y = my_dense(y, self.nb_filters, activation=tf.nn.relu)
            y = my_dense(y, self.nb_filters, activation=tf.nn.relu)
            logits = my_dense(y, self.nb_classes)
            return {self.O_LOGITS: logits,
                    self.O_PROBS: tf.nn.softmax(logits=logits)}
```

attack/pycon_blackbox_keras.py

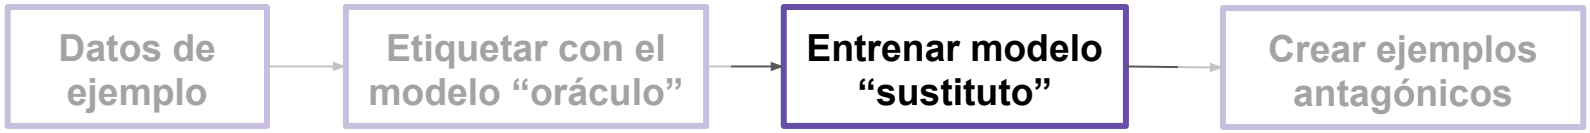


```
class ModelSubstitute(Model):
    def __init__(self, scope, nb_classes, nb_filters=200, **kwargs):
        del kwargs
        Model.__init__(self, scope, nb_classes, locals())
        self.nb_filters = nb_filters

    def fprop(self, x, **kwargs):
        del kwargs
        my_dense = functools.partial(
            tf.layers.dense, kernel_initializer=HeReLuNormalInitializer)
        with tf.variable_scope(self.scope, reuse=tf.AUTO_REUSE):
            y = tf.layers.flatten(x)
            y = my_dense(y, self.nb_filters, activation=tf.nn.relu)
            y = my_dense(y, self.nb_filters, activation=tf.nn.relu)
            logits = my_dense(y, self.nb_classes)
            return {self.O_LOGITS: logits,
                    self.O_PROBS: tf.nn.softmax(logits=logits)}
```

Configuración de una red “sencilla”

attack/pycon_blackbox_keras.py

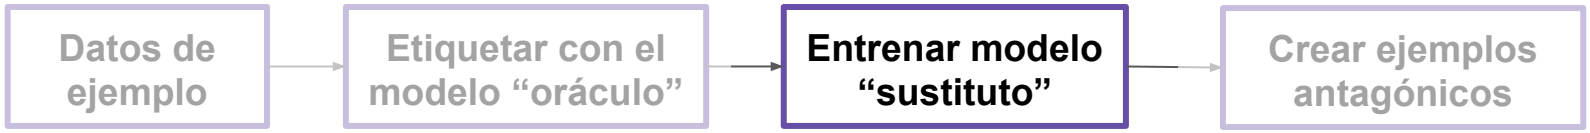


```
# Define TF model graph (for the black-box model)
model_sub = ModelSubstitute('model_s', nb_classes)
preds_sub = model_sub.get_logits(x)
loss_sub = CrossEntropy(model_sub, smoothing=0)
```

attack/pycon_blackbox_keras.py

Datos de ejemplo → Etiquetar con el modelo “oráculo” → **Entrenar modelo “sustituto”** → Crear ejemplos antagónicos

attack/pycon_blackbox_keras.py

Datos de ejemplo → Etiquetar con el modelo “oráculo” → **Entrenar modelo “sustituto”** → Crear ejemplos antagónicos

```
# Train the substitute and augment dataset alternatively
for rho in xrange(data_aug):
    print("Substitute training epoch #"  + str(rho))
    train_params = {'nb_epochs': nb_epochs_s, 'batch_size': batch_size,
        'learning_rate': learning_rate}
    train(sess, loss_sub, x, y, X_sub, to_categorical(Y_sub, nb_classes),
          init_all=False, args=train_params, rng=rng,
          var_list=model_sub.get_params())

    if rho < data_aug - 1:
        lmbda_coef = 2 * int(int(rho / 3) != 0) - 1
        X_sub = jacobian_augmentation(sess, x, X_sub, Y_sub, grads,
                                      lmbda_coef * lmbda , aug_batch_size)

        Y_sub = np.hstack([Y_sub, Y_sub])
        X_sub_prev = X_sub[int(len(X_sub)/2):]
        eval_params = {'batch_size': batch_size}
        bbox_val = batch_eval(sess, [x], [bbox_preds], [X_sub_prev],
                              args=eval_params)[0]
        Y_sub[int(len(X_sub)/2):] = np.argmax(bbox_val, axis=1)
```

attack/pycon_blackbox_keras.py

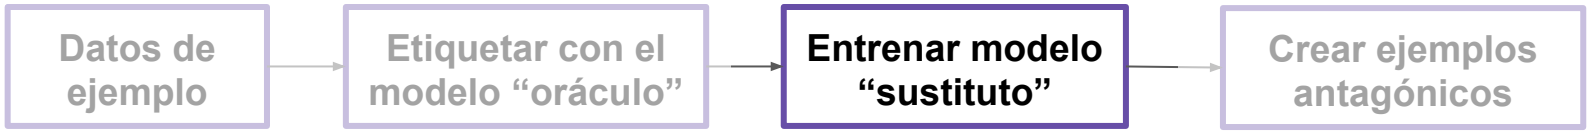


```
# Train the substitute and augment dataset alternatively
for rho in xrange(data_aug):
    print("Substitute training epoch #" + str(rho))
    train_params = {'nb_epochs': nb_epochs_s, 'batch_si
        'learning_rate': learning_rate}
    train(sess, loss_sub, x, y, X_sub, to_categorical(Y_sub, nb_classes),
          init_all=False, args=train_params, rng=rng,
          var_list=model_sub.get_params())

    if rho < data_aug - 1:
        lmbda_coef = 2 * int(int(rho / 3) != 0) - 1
        X_sub = jacobian_augmentation(sess, x, X_sub, Y_sub, grads,
                                      lmbda_coef * lmbda, aug_batch_size)

        Y_sub = np.hstack([Y_sub, Y_sub])
        X_sub_prev = X_sub[int(len(X_sub)/2):]
        eval_params = {'batch_size': batch_size}
        bbox_val = batch_eval(sess, [x], [bbox_preds], [X_sub_prev],
                              args=eval_params)[0]
        Y_sub[int(len(X_sub)/2):] = np.argmax(bbox_val, axis=1)
```

Entrenamiento del sustituto

Generación de datos sintéticos (opcional)

attack/pycon_blackbox_keras.py

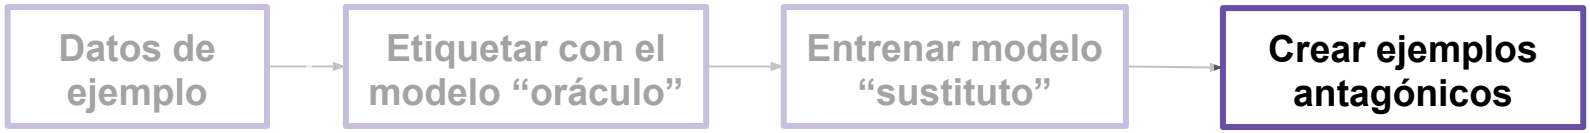


```
# Initialize the Fast Gradient Sign Method (FGSM) attack object.
fgsm_par = {'eps': 0.3, 'ord': np.inf, 'clip_min': 0., 'clip_max': 1.}
fgsm = FastGradientMethod(model_sub, sess=sess)

# Generate adversarial images
x_adv_sub = fgsm.generate(x, **fgsm_par)
adv_images = sess.run(x_adv_sub, feed_dict={x: x_test})
```

attack/pycon_blackbox_keras.py

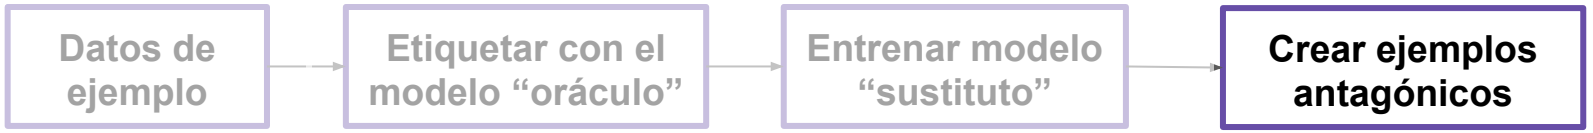


```
# Initialize the Fast Gradient Sign Method (FGSM) attack object.
fgsm_par = {'eps': 0.3, 'ord': np.inf, 'clip_min': 0., 'clip_max': 1.}
fgsm = FastGradientMethod(model_sub, sess=sess)

# Generate adversarial images
x_adv_sub = fgsm.generate(x, **fgsm_par)
adv_images = sess.run(x_adv_sub, feed_dict={x: x_test})
```

Generación de ejemplos antagónicos

attack/pycon_blackbox_keras.py

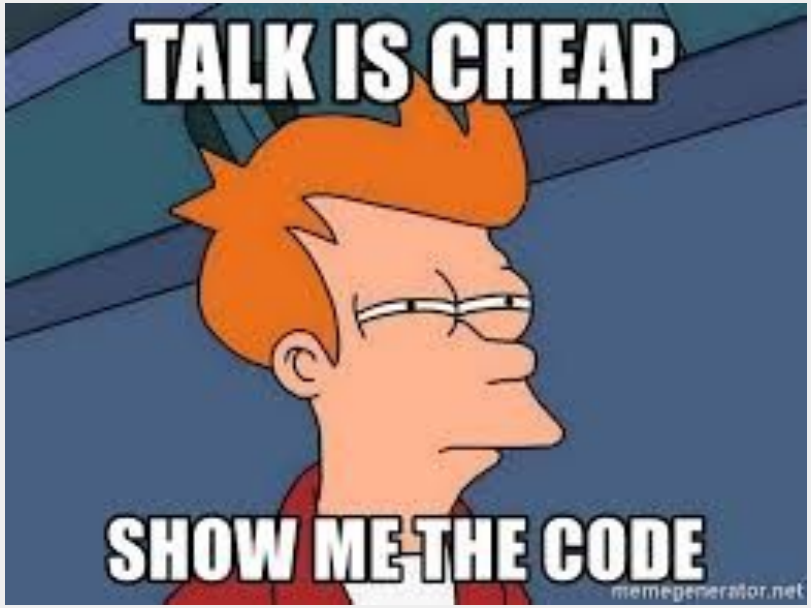

https://github.com/aliciapj/pycon18-attack

Resultados

Predictions	
Bread	0.99288
Soup	0.00663
Dessert	0.00046
Egg	0.00001
Dairy product	0.00001

Predictions	
Dessert	0.99995
Bread	0.00004
Soup	0.00001
Non food	0.00000
Fried food	0.00000

Resultados

Predictions	
Dessert	0.45860
Meat	0.42155
Fried food	0.11669
Dairy product	0.00191
Seafood	0.00062

Predictions	
Dairy product	0.96893
Dessert	0.02798
Fried food	0.00102
Meat	0.00075
Soup	0.00056

Resultados

Predictions

Dairy product	0.97058
Dessert	0.02939
Egg	0.00003
Seafood	0.00000
Soup	0.00000

Predictions

Dessert	0.99279
Dairy product	0.00668
Egg	0.00030
Seafood	0.00021
Soup	0.00002

Resultados

Predictions	
Non food	0.89039
Seafood	0.05469
Dessert	0.03103
Fried food	0.01078
Meat	0.00689

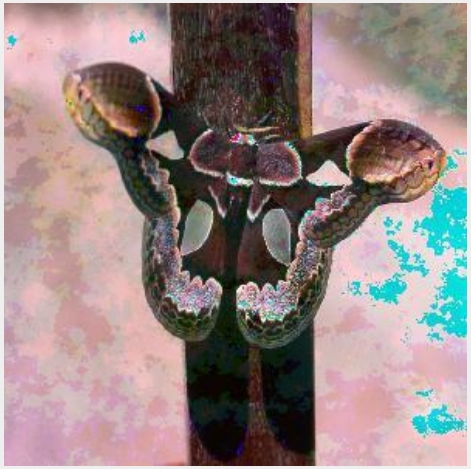

Predictions	
Seafood	0.91692
Dessert	0.07600
Fried food	0.00168
Non food	0.00164
Bread	0.00126

Resultados

Predictions	
Non food	0.59072
Dessert	0.34936
Soup	0.05911
Seafood	0.00035
Egg	0.00026

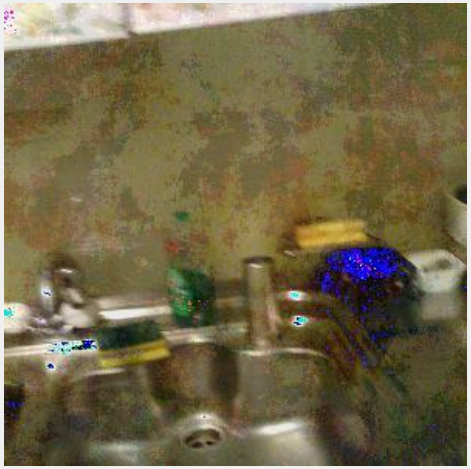

Predictions	
Soup	0.36556
Seafood	0.28649
Bread	0.11913
Meat	0.10086
Dairy product	0.08910

Discusión

¿Cómo afecta a nuestros sistemas y algoritmos?

Ejemplos reales

¡Los ejemplos antagónicos funcionan incluso cuando son impresos y fotografiados a resoluciones estándar!

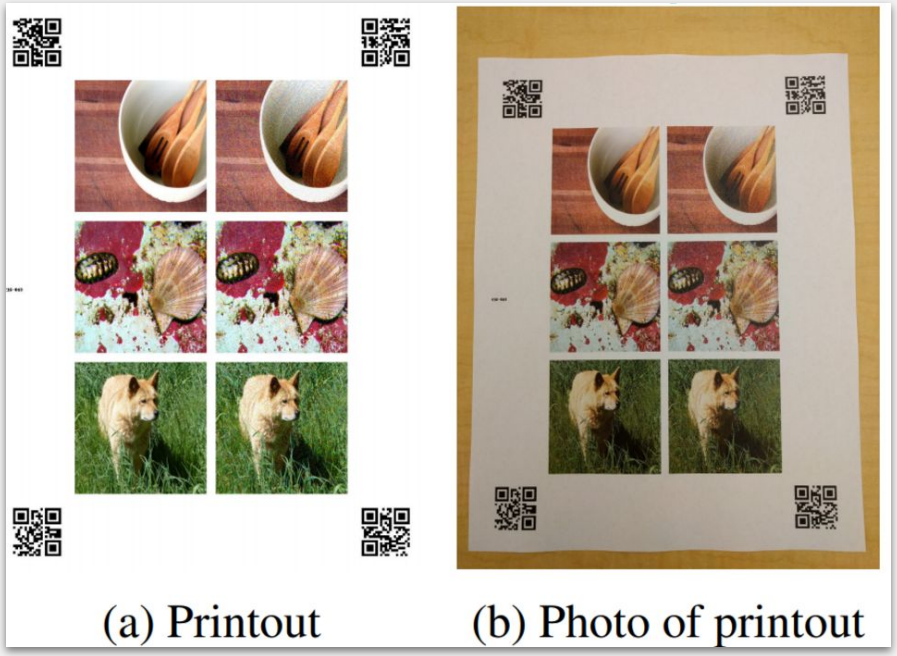

"Practical Black-Box Attacks against Machine Learning". *Papernot et. al.*

Ejemplos reales

Original - library (76%)

Antagónica -prison (52%)

Original - washer (54%)

Antagónica - doormat (35%)

"Adversarial examples in the physical world". *Kurakin et. et.*

Ejemplos reales

Señales de tráfico

- Dataset GTSRD

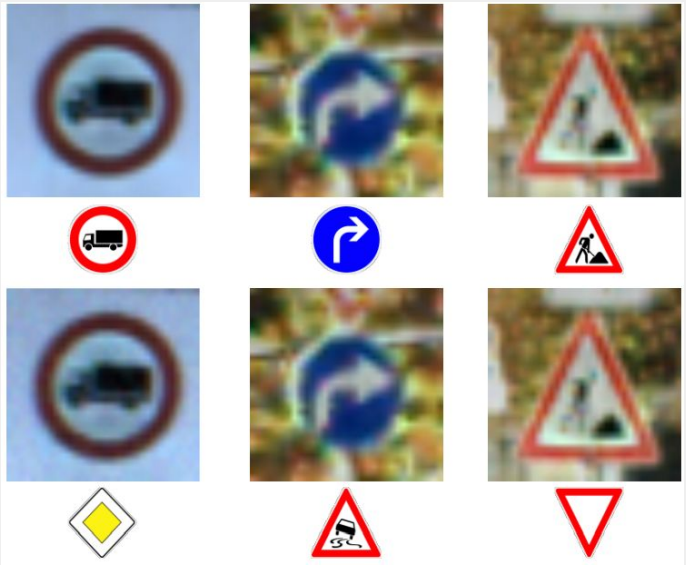

"Practical Black-Box Attacks against Machine Learning". *Papernot et. al.*

Cómo defendernos

¿Qúe podemos hacer?

1. **No es fácil. Vuestras APIs son vulnerables.**
2. Todavía no existe un método infalible
3. La propuestas actuales se basan en las redes neuronales

Estrategia reactiva

- Intentar detectar y anular el ataque.
- Aumentar el tamaño de las entradas o la complejidad de la red para suponer mayor esfuerzo al sistema atacante.

Estrategia proactiva

- Crear modelos más robustos a los ataques.
- Técnicas relacionadas con el entrenamiento de la red.

Estrategias proactivas

Adversarial training
El dataset de entrenamiento del modelo se enriquece añadiendo ejemplos antagónicos creados por nosotros. Aumenta la robustez del modelo y sirve como factor regularizador.

Defensive distillation
Aplica el principio de entrar un modelo sustituto para reducir la confianza de las predicciones del sistema. El modelo se entrena sobre distribuciones de probabilidad en vez de etiquetas.

Gradient masking
Intenta ocultar el gradiente. Se ha demostrado que no es válido. El modelo sustituto lo hace inútil.

"Intriguing properties of neural networks". *Szegedy et. al.*
"Distillation as a Defense to Adversarial Perturbations against Deep Neural Networks". *Papernot et. al.*

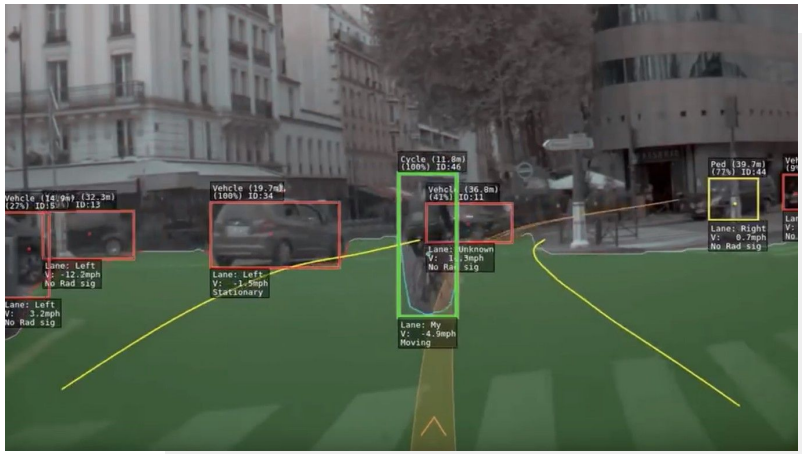

- La IA ya salido del ámbito teórico y la investigación.
- **Technical AI safety** es un campo nuevo, pero con mucho potencial.
- Ya presente en empresas como Google DeepMind, con su *DeepMind safety team*.

- Agente del juego CoastRunners (OpenAI). ¿Buen diseño de métricas?
- Los cimientos de muchas aplicaciones del futuro.

Reflexiones

"Building safe artificial intelligence: specification, robustness, and assurance"

gracias!

¿Alguna pregunta?

@alipeji | alicia@stylesage.co

@fjordonz | javier.ordonez@stylesage.co

We are hiring!!!